

Le minage des données

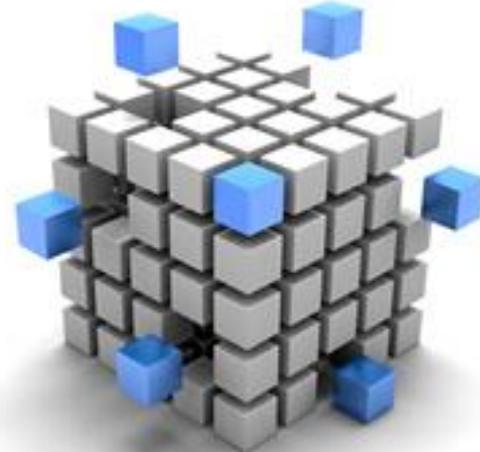


Objectifs

2

Présentation

- Définir le minage de données
- Décrire le procès de minage
- Découvrir les minage sous SQL Server



11.

Le minage des données

Découvrons ensemble le minage des données!!!!

Définir le minage

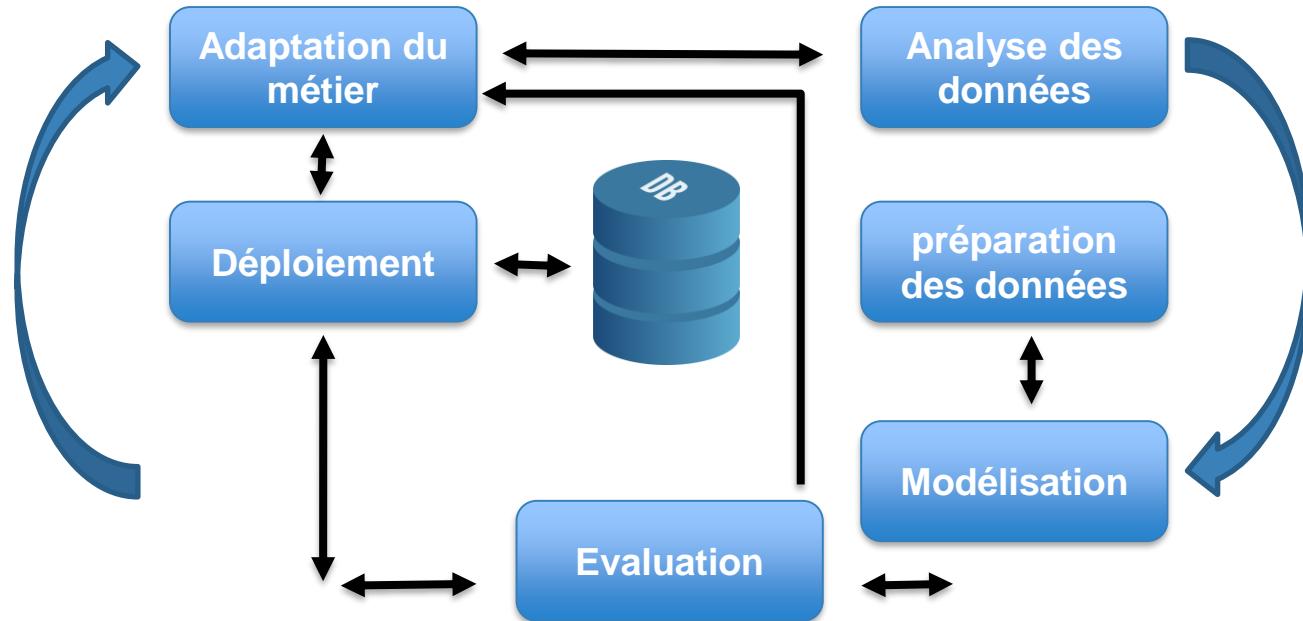
4

C'est quoi?

- ❑ Le minage des données répond au dilemme beaucoup de données et peu d'informations
- ❑ La principale idée derrière le minage c'est la prévision qui est la clé principale du BI
- ❑ Le minage propose un ensemble d'algorithmes prédéfinis sous SQL Server qui permettent de créer des prévisions selon le contexte

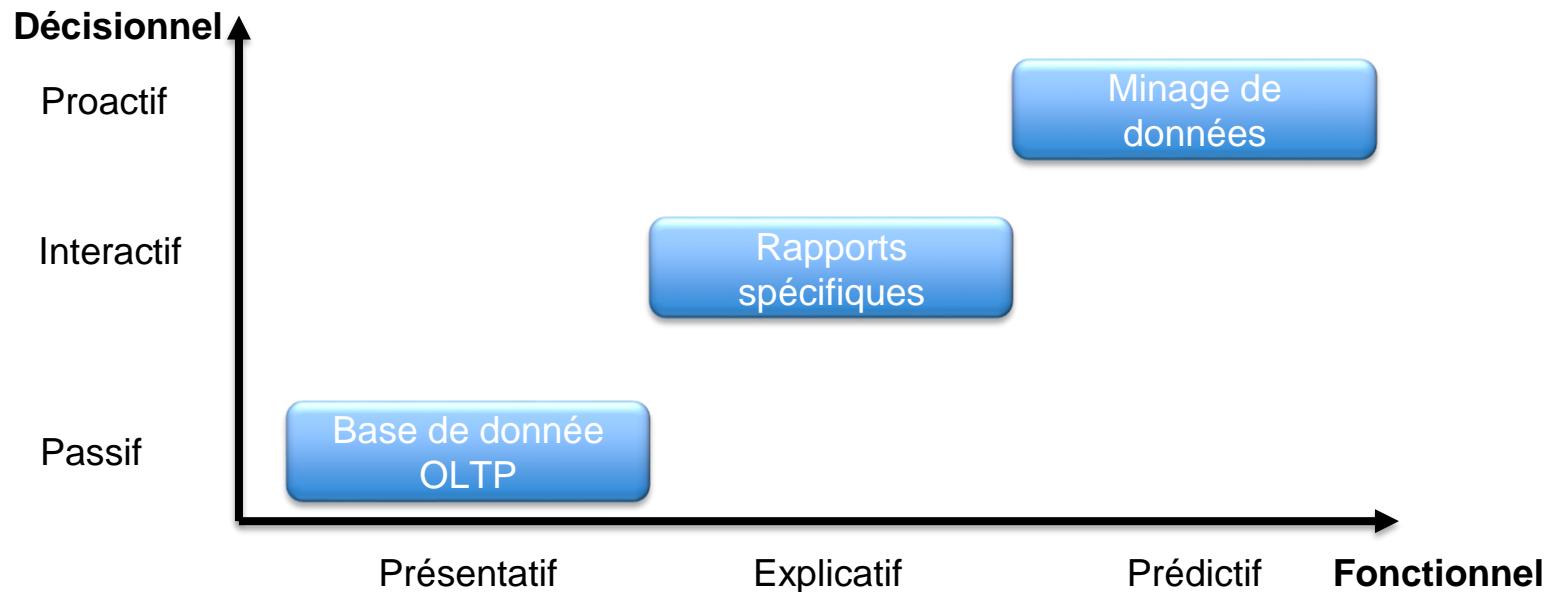


Le procès du minage



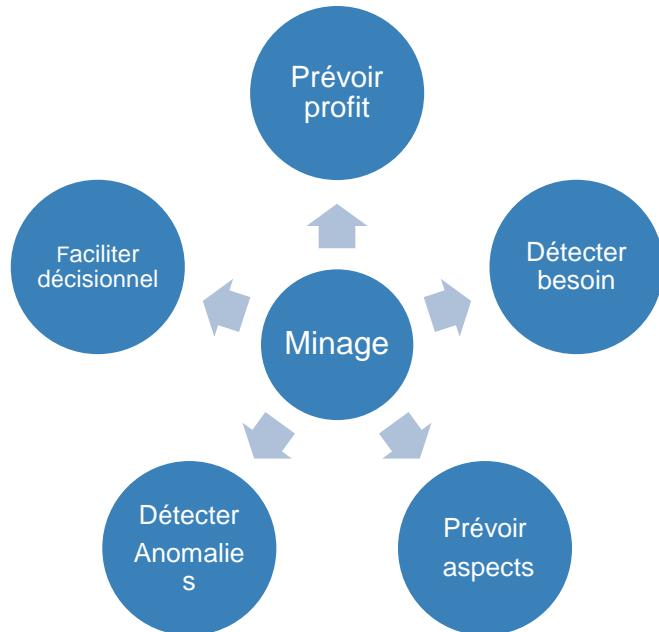
Le procès du minage

6



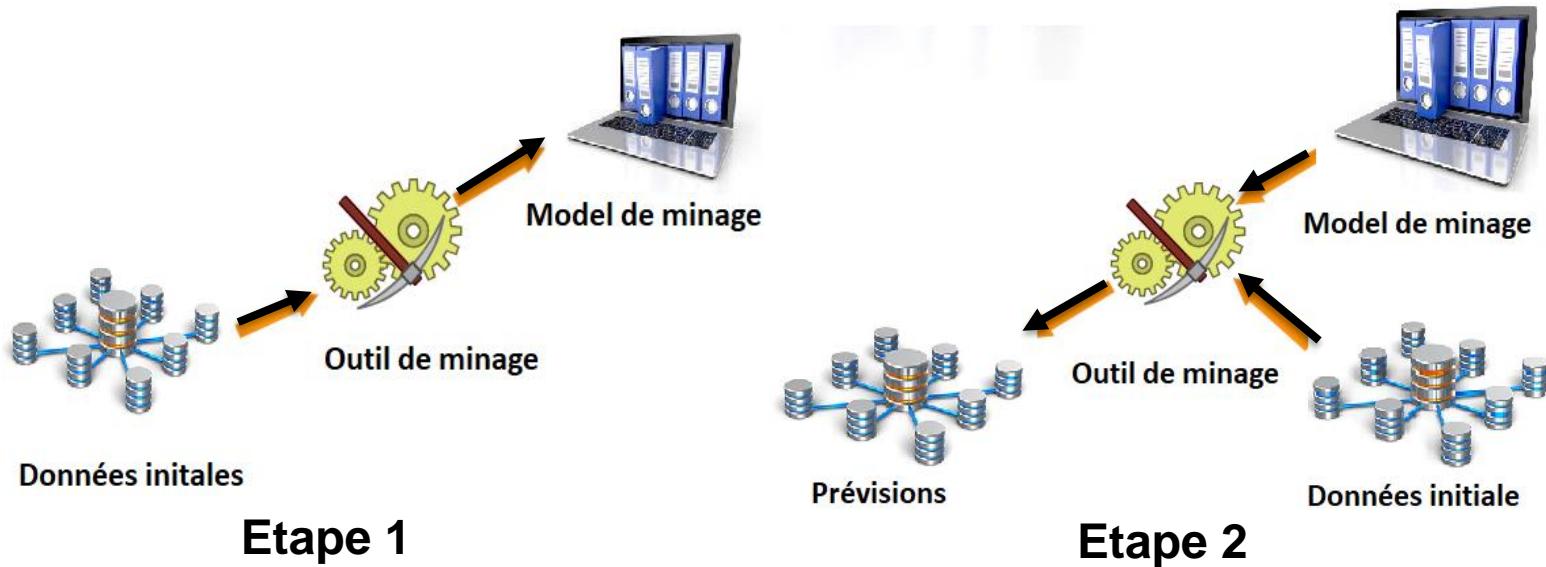
Le procès du minage

7



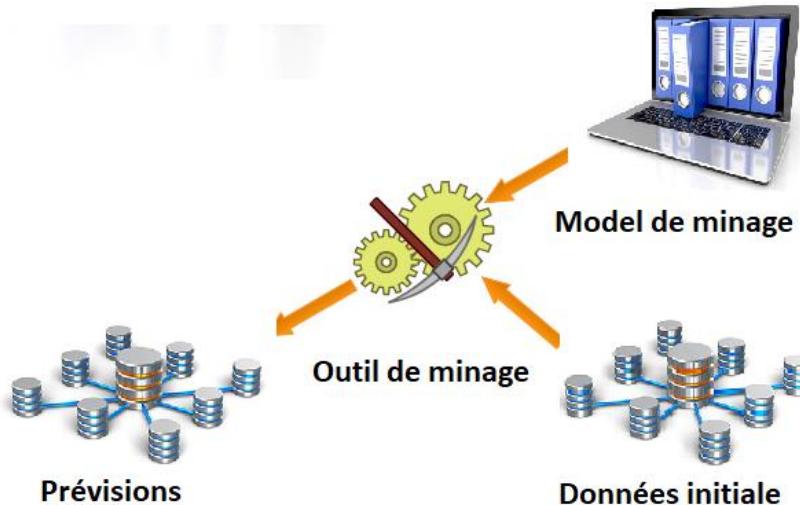
Le procès du minage

8



Le procès du minage

9



Le procès du minage

10

Quel sont les domaines de minage?

- ❑ **Classification:** La ségrégation des cas sur la base d'un critère donné
- ❑ **Régression:** La recherche de corrélation entre plusieurs facteurs
- ❑ **Segmentation:** La détection de bord ou de contour
- ❑ **Association:** La recherche de traits en commun entre les éléments
- ❑ **Prévision:** L'estimation des résultats futur sur la base des études empiriques
- ❑ **Exploration:** L'obtention des informations à caractères explicatives des phénomènes étudiés

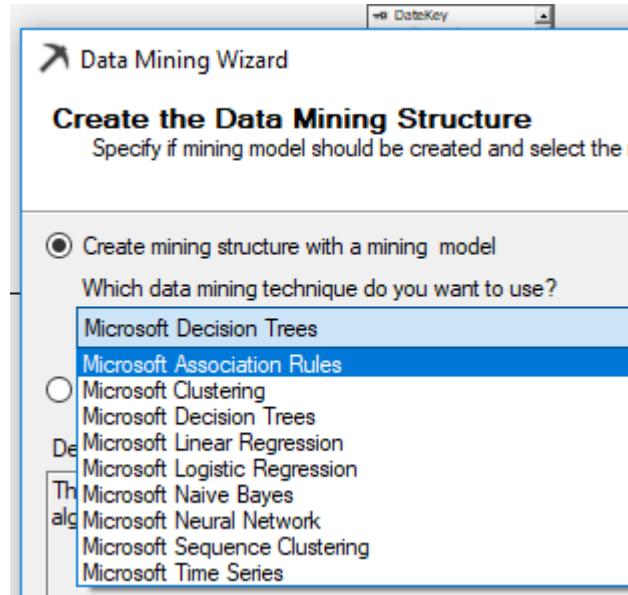


Le miange sous SQL Server

11

Qu'est ce qui nous offre?

- Réduit la complexité de développement des procédés des minages
- Offre 9 algorithmes de minage parmi les plus utilisés
- Une interface simple avec outils visuel intuitifs
- Un Framework pour augmenter les capacités de minage et une parfaite intégration avec les autres outils Microsoft exemple Excel



Microsoft Naïves Bayes

- ❑ C'est un algorithme de classification basé sur le théorème de Bayes
- ❑ C'est un algorithme simple et rapide mais qui ne prend pas en compte l'interdépendance des faits représentés par les divers colonnes
- ❑ Utilisé pour une exploration initiale

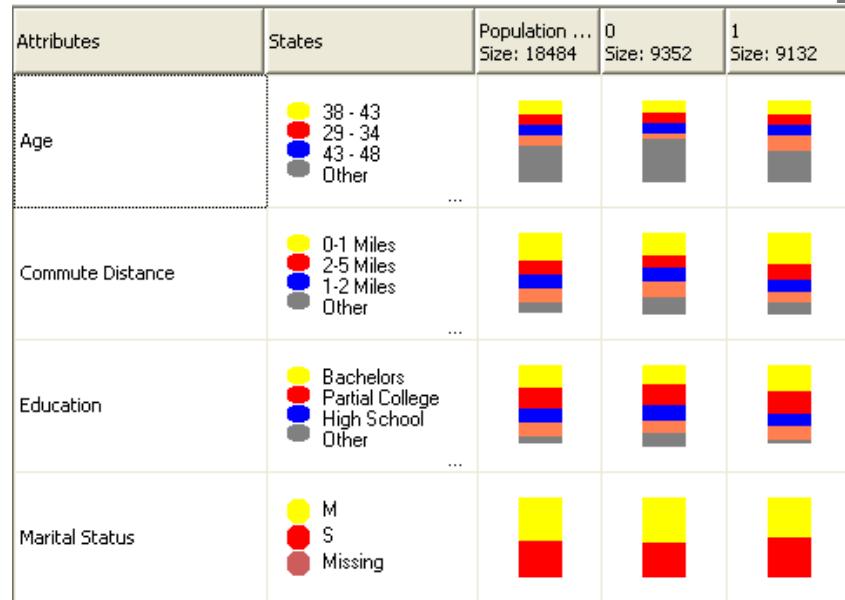
Attributes	Values	Probability
Home Owner	Yes	
Marital Status	Married	
Occupation	Management	
Cars	4	
Region	North America	
Region	Europe	
Occupation	Professional	
Marital Status	Single	
Age	36 - 46	

Le miange sous SQL Server

13

Comment ça fonctionne?

- ❑ Prenons l'exemple d'une compagnie qui veut lancer une compagnie de marketing
- ❑ Elle veut envoyer des mails seulement vers les clients potentiels
- ❑ L'algorithme de Bayes calcule la probabilité de chaque état de chaque colonne d'entrée



Données entrées?

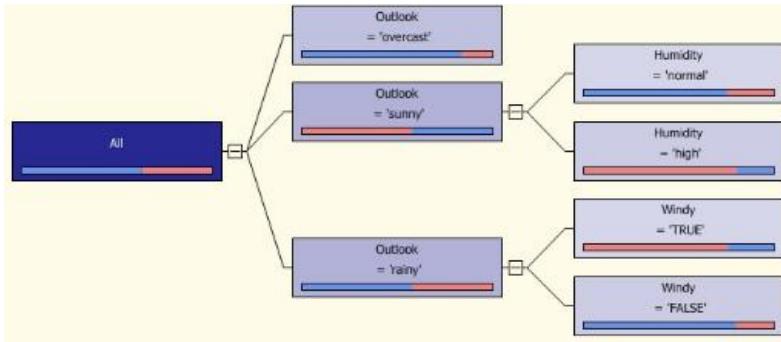
- ❑ **La clé:** L'identifiant au niveau d'une entité sa pourra être numérique ou texte
- ❑ **Les noms de colonnes d'entrée:** Les colonnes qui contiennent les données à prévoir
- ❑ **La colonne de prévision:** Au moins une colonne doit être préservée à la prévision
- ❑ Les données d'entrée doivent être absolument discrètes sinon nous les discrétons
- ❑ Les attributs relatifs aux données d'entrée doivent être indépendants

Le miange sous SQL Server

15

Microsoft Descision Trees

- ❑ C'est un algorithme de classification et de régression en mode discret et continu
- ❑ Dans un contexte discret, les prévisions se basent sur la relation entre les colonnes celles d'entrée et celle de prévision, c'est la tendance
- ❑ Dans contexte continu, il utilise une simple régression linéaire pour trancher
- ❑ L'algorithme crée un arbre décisionnel relatif à chaque colonne de prévision

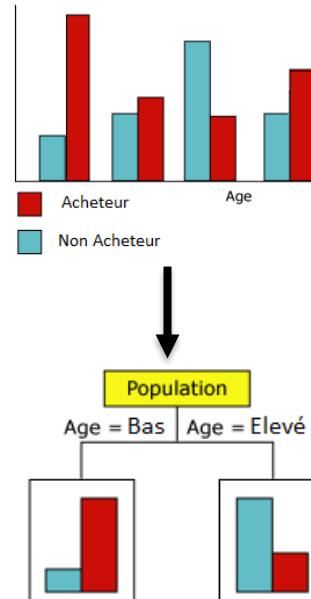


Le miange sous SQL Server

16

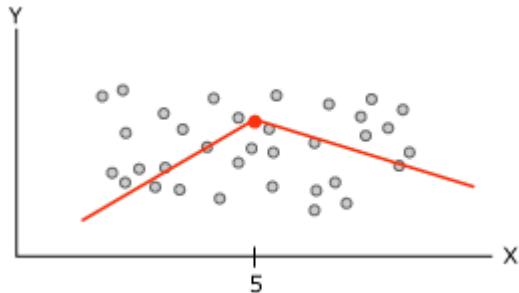
Comment sa fonctionne?

- Dans le contexte discret, prenons l'exemple d'une compagnie qui veut lancer une compagnie de marketing
- Elle veut hiérarchiser les clients envers l'achat d'un produit particulier selon leurs caractéristiques
- Après une corrélation, il présente la prévision au niveau d'un nœud et il passe vers la caractéristique suivante



Comment sa fonctionne?

- ❑ Dans le contexte continu, c'est la régression linéaire qui sera utilisée
- ❑ La segmentation se base sur le point de non linéarité représenté par le model
- ❑ Plusieurs model sont utilisés à la fois pour améliorer le résultat de segmentation



Données entrées?

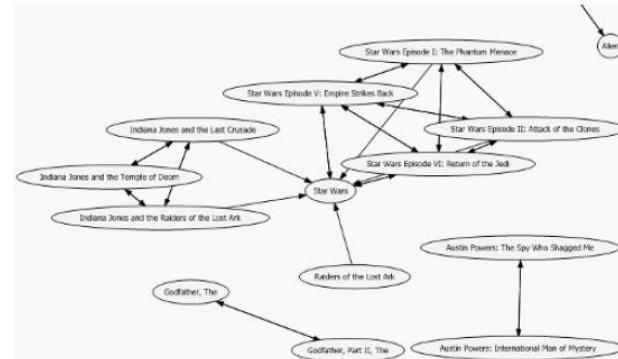
- ❑ **La clé:** L'identifiant au niveau d'une entité numérique ou texte, elle ne doit pas être composée
- ❑ **Les noms de colonnes d'entrée:** Les colonnes qui contiennent les données à prévoir qui peuvent être continues ou discrètes
- ❑ **La colonne de prévision:** Au moins une colonne doit être préservée à la prévision qui peuvent être continues ou discrètes

Le miange sous SQL Server

19

Microsoft Associations

- ❑ C'est un algorithme de recommandation qui se base sur des études empiriques
- ❑ Une association est composé d'un ensemble dit de **Itemsets**
- ❑ Exemple, nous avons deux produits X et Y, en compte le nombre de fois où les X et Y sont au panier
- ❑ La prévision sera basée sur le nombre de fois d'associations X,Y effectuées par le client



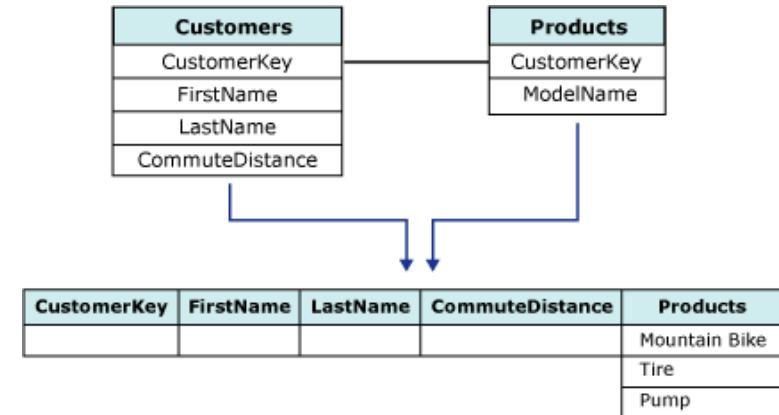
Le miange sous SQL Server

20

Données entrées?

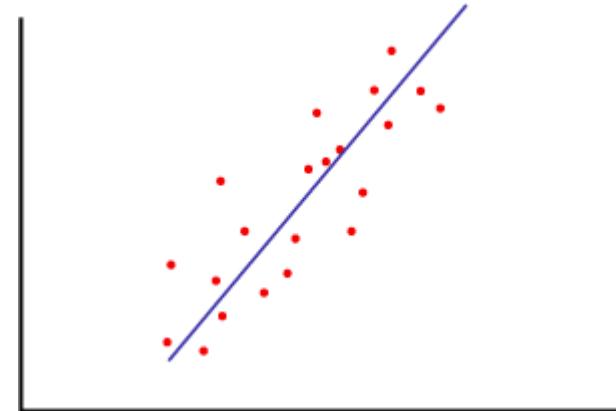
- ❑ **La clé:** L'identifiant au niveau d'une entité numérique ou texte, il ne doit pas être composé
- ❑ **Les noms de colonnes d'entrée:** Les colonnes qui contiennent les données à prévoir doivent être discrètes
- ❑ **La colonne de prévision:** Une seule colonne doit être préservée à la prévision, les données doivent être discrètes

Remarque: La colonne de prévision est généralement au niveau d'une table imbriquée



Microsoft Linear regressions

- ❑ C'est un algorithme considéré comme une variance de Binary Tree utilisé dans un contexte continu
- ❑ Il permet de prévoir une corrélation entre deux phénomènes différents
- ❑ Il est possible de prévoir la relation entre la hausse des ventes d'un produit X par rapport à la baisse d'un produit Y

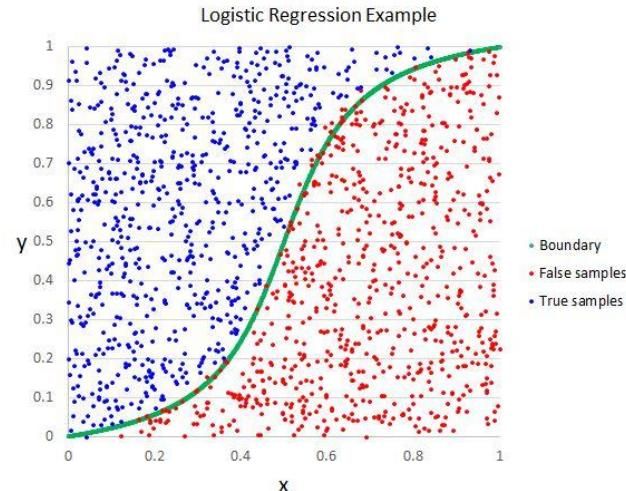


Données entrées?

- ❑ **La clé:** L'identifiant au niveau d'une entité, il ne doit pas être composé
- ❑ **Les noms de colonnes d'entrée:** Les colonnes qui contiennent les données à prévoir, elles doivent être continues
- ❑ **La colonne de prévision:** Au moins une colonne doit être préservée à la prévision, les données doivent être continues et non de type date

Microsoft logistic regressions

- ❑ C'est un algorithme considéré comme un algorithme de régression non linéaire
- ❑ Il permet de prévoir une corrélation entre deux phénomènes différents comme le modèle linéaire mais pour prévoir plusieurs facteurs à la fois
- ❑ Prenons un groupe de personnes homogènes et leur attitude à acheter un produit X, l'algorithme peut déterminer la probabilité d'achat de ce produit de l'une de ces personnes



Données entrées?

- ❑ **La clé:** L'identifiant au niveau d'une entité non composé
- ❑ **Les colonnes d'entrée:** Les colonnes qui contiennent les données à prévoir
- ❑ **La colonne de prévision:** Au moins une colonne doit être préservée à la prévision

Remarque: Les colonnes imbriquées ne sont pas prises en considération comme colonnes de prévision dans ce cas

Microsoft Neutral Network

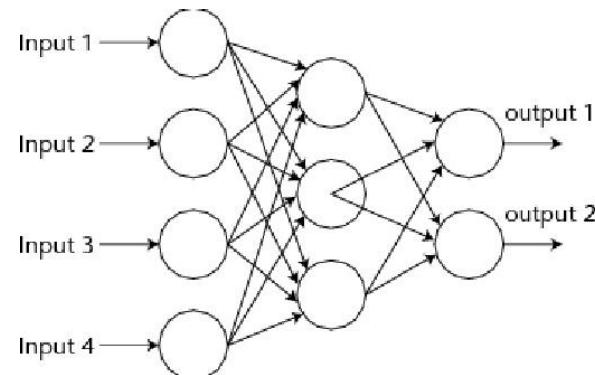
- ❑ L'algorithme Microsoft Neural Network est une implémentation du réseau neuronal adaptable pour Machine Learning
- ❑ L'algorithme fonctionne en testant chaque état possible de l'attribut d'entrée sur chaque état possible de l'attribut prévisible
- ❑ Les probabilités sont calculées pour chaque combinaison en fonction des données d'entraînement
- ❑ La sortie de cet algorithme est multiple, il calcule la probabilité cas par cas
- ❑ Ces probabilités peuvent être ensuite réutilisées dans des opérations de classification ou régression
- ❑ Il est possible de le combiner avec une analyse des associations

Le miange sous SQL Server

26

Microsoft Neutral Network

- ❑ Il est possible de l'utiliser pour mesurer le degré de succès d'une campagne de marketing
- ❑ Prévoir les comportements boursiers
- ❑ Minage du texte
- ❑ En général, toute prédiction qui abouti à plusieurs alternatives à la fois

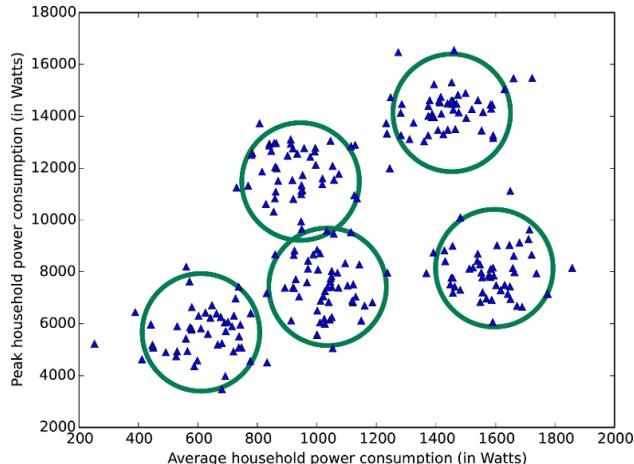


Données entrées?

- ❑ **Couche d'entrée:** les nœuds d'entrée comprennent des données et leurs probabilités.
- ❑ **Couche cachée:** c'est l'endroit où les différentes probabilités des entrées sont attribuées aux poids
- ❑ **Couche de sortie:** Les nœuds de sortie représentent des valeurs d'attribut prévisibles pour le modèle d'exploration de données

Microsoft Clustering

- ❑ C'est un algorithme de segmentation ou de cluster et d'exploration
- ❑ Itère sur les cas dans un ensemble de données pour les regrouper en clusters qui contiennent des caractéristiques similaires
- ❑ Ces groupements sont utiles pour
 - ✓ Explorer les données
 - ✓ Identifier les anomalies dans les données
 - ✓ Créer des prédictions

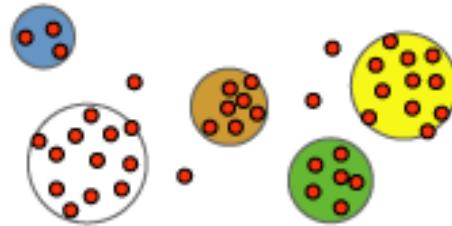


Le miange sous SQL Server

29

Comment ça fonctionne?

- ❑ L'algorithme identifie d'abord les relations dans un ensemble de données et génère une série de clusters basés sur ces relations
- ❑ Un diagramme de dispersion est un moyen utile de représenter visuellement les données
- ❑ Après avoir défini les clusters, l'algorithme calcule à quel point les grappes représentent les groupements des points et l'opération à nouveau jusqu'à arriver au seuil limite



Données entrées?

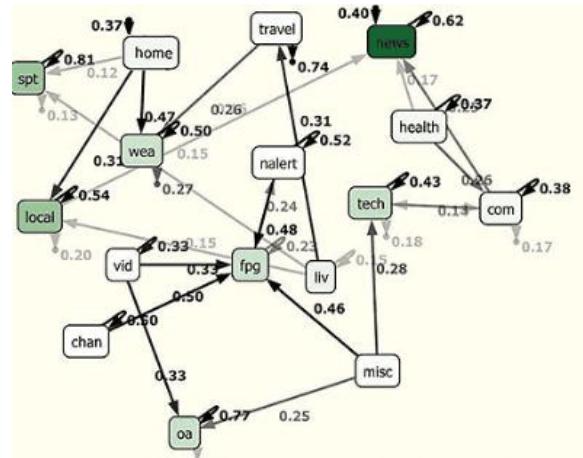
- ❑ **La clé:** L'identifiant au niveau d'une entité non composée qui peut être numérique ou texte
- ❑ **Les colonnes d'entrée:** Les colonnes qui contiennent les données à prévoir
- ❑ **Les colonnes de prévision:** Elle est optionnelle cette fois ci car l'algorithme n'a pas besoin d'une colonne prévisible pour construire le modèle, la colonne de prévision doit être marquée comme `PredictOnly`

Le miange sous SQL Server

31

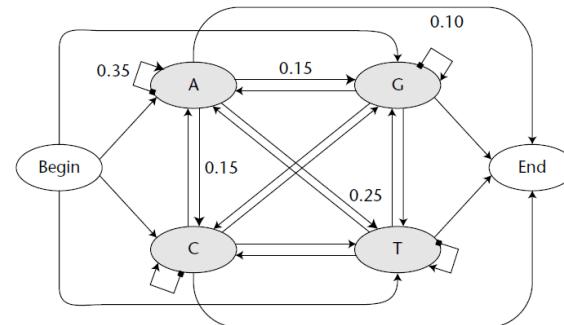
Microsoft Sequence Clustering

- Vous pouvez utiliser cet algorithme pour explorer des données contenant des événements pouvant être liés dans une séquence
- l'algorithme trouve les séquences les plus courantes, et effectue le regroupement pour trouver des séquences similaires
- Exemple les zones de click au niveau des pages d'un site web



Comment sa fonctionne?

- ❑ L'algorithme est hybride il combine les techniques de regroupement avec la chaîne de Markov
- ❑ Les données représentent généralement une série d'événements ou d'états transitions dans un ensemble de données
- ❑ L'algorithme examine toutes les probabilités de transition et mesure les différences entre toutes les séquences possibles



Transition probabilities:
 $P(x_i = G|x_{i-1}=A) = 0.15$
 $P(x_i = C|x_{i-1}=A) = 0.15$
 $P(x_i = T|x_{i-1}=A) = 0.25$
 $P(x_i = A|x_{i-1}=A) = 0.35$
 $P(x_i = End|x_{i-1}=A) = 0.10$

Données entrées?

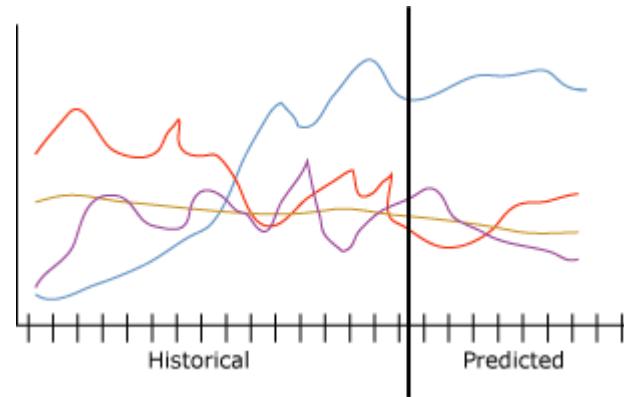
- ❑ **La clé**: L'identifiant au niveau d'une entité non composée
- ❑ **Une colonne de séquence** : Cette colonne doit exister dans une table imbriquée, elle contient les identifiants des séquences triables
- ❑ **Des colonnes non séquentielles** : Elles sont optionnelles

Le miange sous SQL Server

34

Microsoft Time Series

- ❑ L'algorithme fournit plusieurs sous algorithmes optimisés pour la prévision de valeurs continues
- ❑ Tel que les ventes de produits, au fil du temps
- ❑ Une caractéristique importante de l'algorithme c'est qu'il peut effectuer une prédiction croisée.
- ❑ Les ventes observées d'un produit peuvent influer les ventes prévues d'un autre produit



Le miange sous SQL Server

35

Comment sa fonctionne?

- ❑ L'algorithme se base sur deux principaux algorithmes ARTXP pour l'analyse des flux de données rapides et ARIMA pour l'analyse des flux de données moins rapides
- ❑ Il est possible d'utiliser une combinaison des deux algorithmes
- ❑ Un seul modèle peut contenir des ventes de plusieurs produits, à condition qu'il n'y ait qu'un enregistrement de nom de produit unique pour chaque tranche de temps



Données entrées?

- ❑ **La clé:** L'identifiant au niveau d'une entité numérique ou date seulement
- ❑ **Une colonne de prévision:** Cette colonne doit contenir des valeurs continues , la colonne doit contenir des valeurs continues et les valeurs doivent être uniques pour chaque série
- ❑ **Des colonnes clés d'indentification optionnelles :** Elles sont optionnelles, elles doivent contenir des données uniques

Le miange sous SQL Server

37

Classification	Régression	Ségmentation	Prévision	Association
<ul style="list-style-type: none">• Decision Trees• Logistic Regression• Naïve Bayes• Neural Networks	<ul style="list-style-type: none">• Decision Trees• Linear Regression• Logistic Regression• Neural Networks	<ul style="list-style-type: none">• Clustering• Sequencial clustering	<ul style="list-style-type: none">• Time Series	<ul style="list-style-type: none">• Association Rules• Decision Trees

Les méthodes d'applications

- ❑ **SSDT:** L'outil offre déjà un environnement visuel confortable pour créer des structure de minage
- ❑ **DMX:** Il est possible de créer des model de minage à travers un langage très proche du SQL
- ❑ **ADOMD.Net:** Cet API permet d'intégrer les minage dans les applications personnalisées
- ❑ **Les plugins:** Comme les plugin Excel

```
/*Exemple de structure de requête  
DMX*/  
SELECT FLATTENED TOP <colonnes>  
FROM <model>  
PREDICTION JOIN <table>  
ON <mappage>  
WHERE <filter>  
ORDER BY <expression>
```

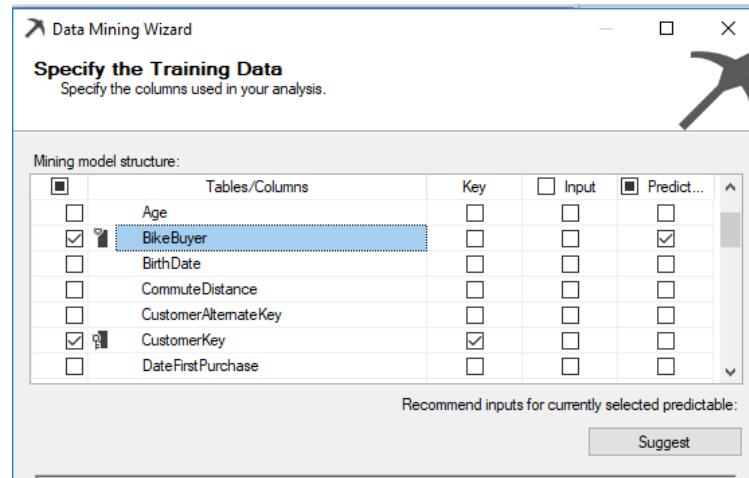
“

*Lab:Structure de minage de classification
sous SSDT*

Plusieurs dimensions et une seule mesure 40

Création de la structure de minage

- ❑ Création de structure de minage
- ❑ Nous utilisons [AdventureWorkDW2012].[vTargetMail] comme table d'entrée
- ❑ Nous spécifions CustomerKey comme clé et BikeBuyer comme colonne de prévision

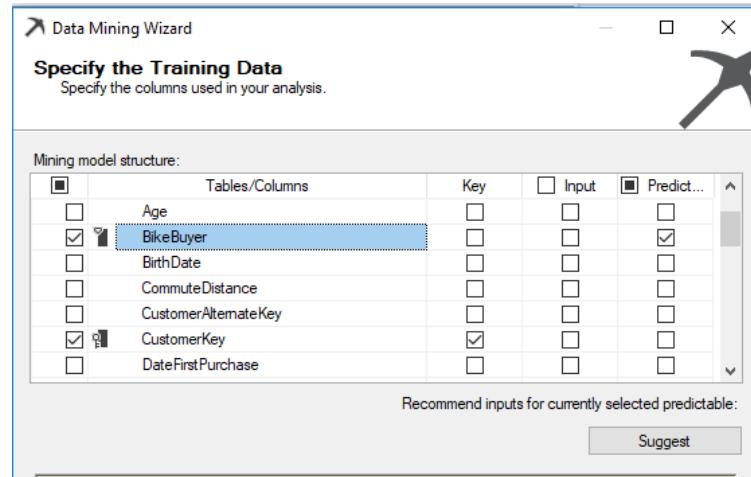


Plusieurs dimensions et une seule mesure

41

Création de la structure de minge

- ❑ Nous cliquons sur le bouton suggest pour voir les suggestions d'entrées
- ❑ Nous choisissons comme entrées
 - ✓ Age
 - ✓ Nombre de voitures
 - ✓ Nombre d'enfants
 - ✓ Niveau
 - ✓ Salaire annuel
 - ✓ Région

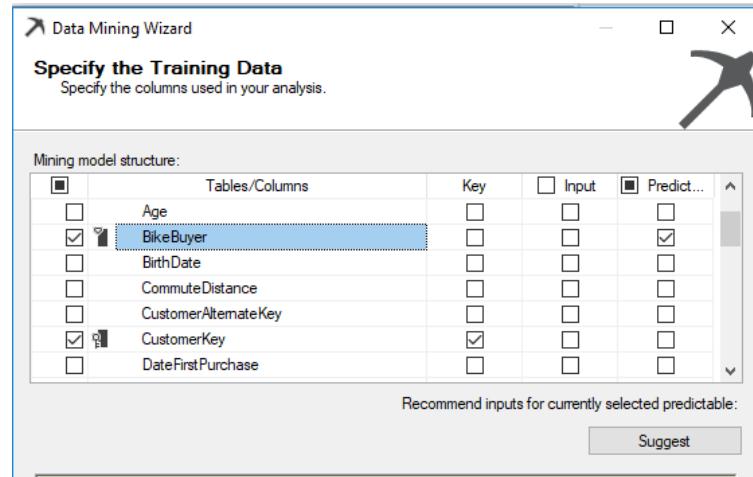


Plusieurs dimensions et une seule mesure

42

Création de la structure de minge

- ❑ Nous cliquons sur le bouton suggest pour voir les suggestions d'entrées
- ❑ Nous choisissons comme entrées
 - ✓ Age
 - ✓ Nombre de voitures
 - ✓ Nombre d'enfants
 - ✓ Niveau
 - ✓ Salaire annuel
 - ✓ Région



Plusieurs dimensions et une seule mesure

43

Création de la structure de minage

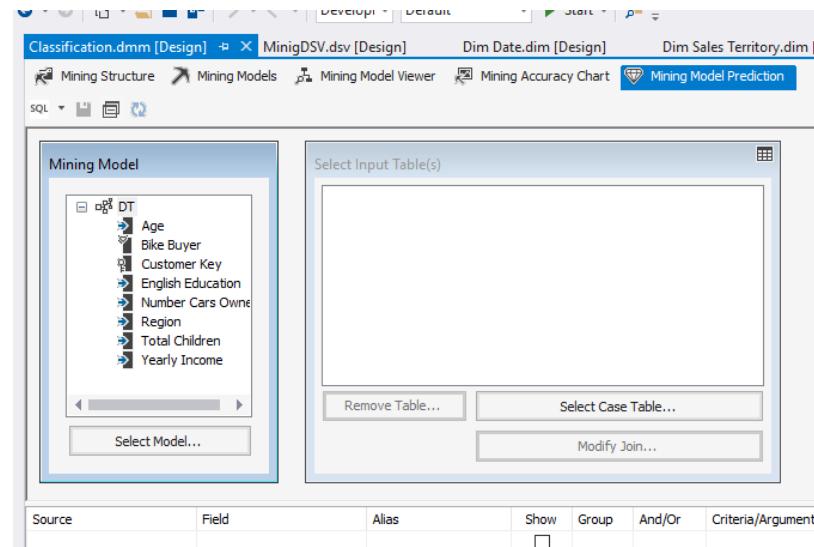
- ❑ Nous explorons les données un fois le modèle est créé
- ❑ Nous ajoutons les modèles de minage à partir de l'onglet **Mining Models**
 - ✓ Decision Tree
 - ✓ Logistic Regression
 - ✓ Neutral Network

Structure	DT	LR	NN
Age	Microsoft_Decision_Trees	Microsoft_Logistic_Regression	Micro
Bike Buyer	Input	Input	Igno
Customer Key	PredictOnly	PredictOnly	Pred
English Education	Key	Key	Key
Number Cars Owned	Input	Input	Inpu
Region	Input	Input	Igno
Total Children	Input	Input	Inpu
Yearly Income	Input	Input	Igno

Plusieurs dimensions et une seule mesure 44

Création de la structure de minge

- Au niveau de l'onglet **Minig Model Viewer** nous essayons d'explorer les divers model ajoutés
- Essayons l'onglet **Dependency Network** sous **Minig Model Viewer**
- Allons vers L'onglet **Mining Model Prediction**

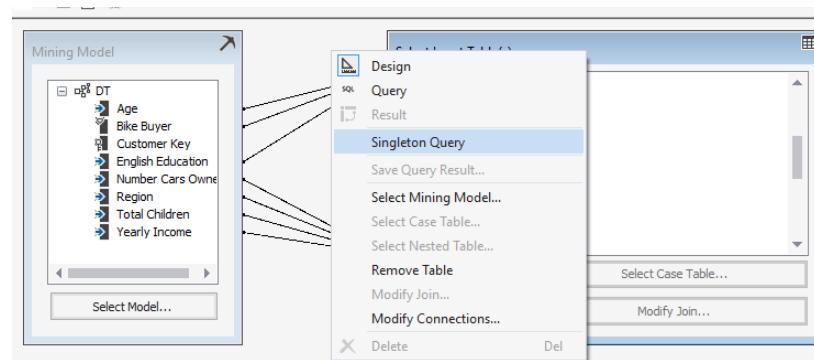


Plusieurs dimensions et une seule mesure

45

Création de la structure de mining

- ❑ Allons vers L'onglet Mining Model Prediction essayons
- ❑ Essayons de selectionner le model decision tree
- ❑ Choisissons la table vTargetMail à droite
- ❑ Il est possible de raisonner niveau table ou niveau cas singulier



Plusieurs dimensions et une seule mesure

46

Création de la structure de minge

- Choisissons le cas de prévision singulier
- Avec les paramètres suivants

Source	Field	Alias	Show	Group	And/Or	Criteria/Argument
Prediction Function	PredictProbability		<input checked="" type="checkbox"/>			[DT].[Bike Buyer],1
			<input type="checkbox"/>			

Plusieurs dimensions et une seule mesure

47

Création de la structure de minge

- Choisissons l'option Query pour voir la requête en DMX
- Choisissons le résultat pour voir la prévision en pourcentage
- Revenons vers le raisonnement niveau table et répetons les configurations

The screenshot shows the Microsoft Data Mining Wizard interface. On the left, there's a navigation pane with 'Design', 'Query' (which is selected), and 'Result'. Below it, a tree view lists mining model columns: Age, Bike Buyer, Customer Key, English Education, and Number Cars Owned. To the right, a 'Singleton Query Input' window displays a table with five rows corresponding to the columns in the tree. The table has two columns: 'Mining Model Column' and its value. At the bottom, a query editor window shows the following DMX code:

```
SELECT
    (PredictProbability([DT].[Bike Buyer],1)) as [Achat]
From
    [DT]
NATURAL PREDICTION JOIN
(SELECT 40 AS [Age],
    1 AS [Bike Buyer],
    'High School' AS [English Education],
    1 AS [Number Cars Owned],
    2 AS [Total Children]) AS t
```

“

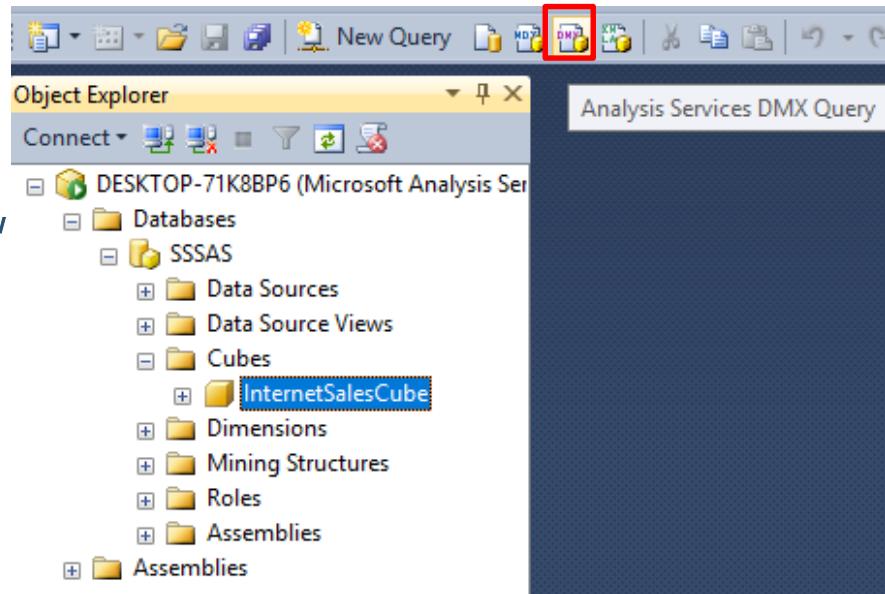
Lab:Le minage sous SSMS

Les dimensions usage

49

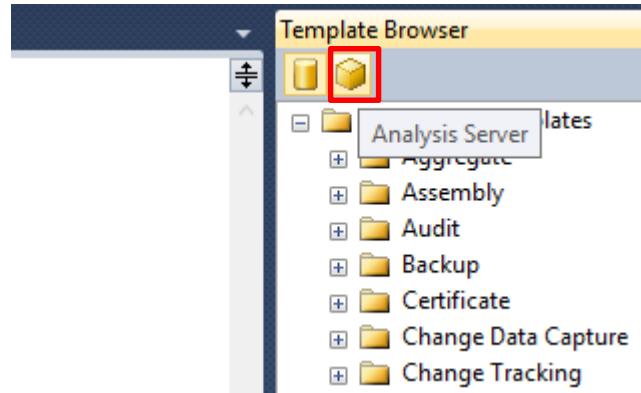
Le mode d'emploi

- ❑ Nous créons une nouvelle requête DMX sous SSMS
- ❑ Cliquons Template Explorer sous le menu View



Le mode d'emploi

- Cliquons **Analysis Server** pour avoir les divers templates DMX
- Choisissons **Base prediction** comme template
- Essayons de reconstruire la requête précédemment faite au niveau de **SSDT**

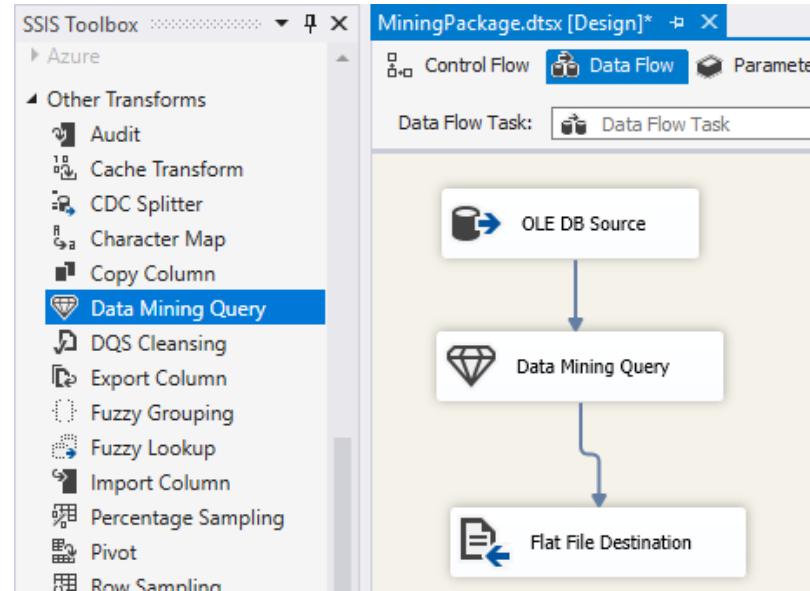


“

Lab:Le minage avec SSIS

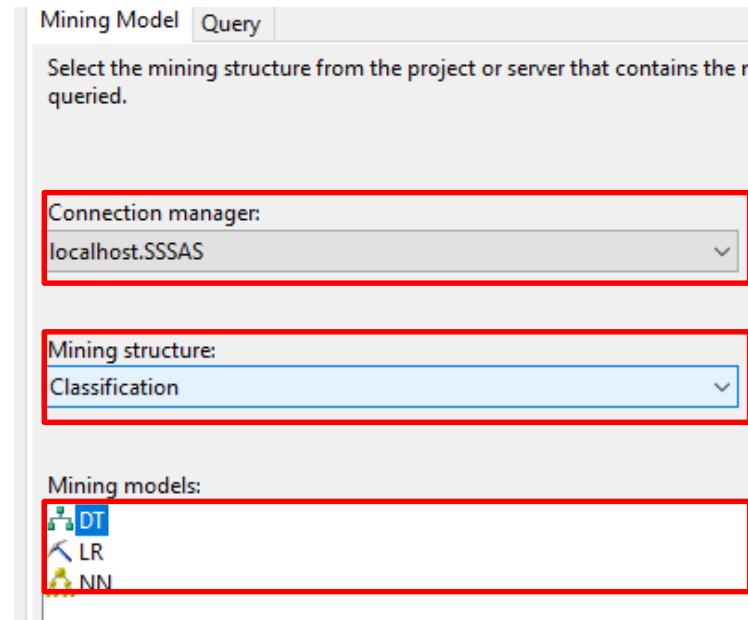
Le mode d'emploi

- Il est possible de miner sous SSIS avec le Task Data Mining Query



Le mode d'emploi

- ❑ Au niveau de l'onglet **Mining Model** parametrons le connection manager
- ❑ Spécifions la structure de minage
- ❑ Choisissons le model de minage



Les dimensions usage

54

Le mode d'emploi

- Construisons la requête de minage avec DMX ou avec l'assistant en cliquant le bouton Build New Query

Mining Model Query

Specify a data mining query either by typing the query or by using the graphical query designer.

Data mining query:

```
SELECT FLATTENED
    (PredictProbability([DT].[Bike Buyer],1)) as [Achat]
From
[DT]
PREDICTION JOIN
@InputRowset AS t
ON
[DT].[Yearly Income] = t.[YearlyIncome] AND
[DT].[Total Children] = t.[TotalChildren] AND
[DT].[English Education] = t.[EnglishEducation] AND
[DT].[Number Cars Owned] = t.[NumberCarsOwned] AND
[DT].[Region] = t.[Region] AND
[DT].[Age] = t.[Age] AND
[DT].[Bike Buyer] = t.[BikeBuyer]
```

Build New Query

Le mode d'emploi

- Plaçons un Data Viewer pour visualiser les données au niveau du package SSIS

